FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA

CIÊNCIA DA COMPUTAÇÃO

KENICHI CAIO YAMAMOTO - RM: 569815

RODGER COSTA RIOS - RM: 571438

RELATÓRIO DE ANÁLISE ESTATÍSTICA DA VULNERABILIDADE SOCIAL NOS MUNICÍPIOS BRASILEIROS:

Análise de dados municipais aplicada ao desenvolvimento de soluções de apoio ao cidadão

SÃO PAULO

2026

KENICHI CAIO YAMAMOTO - RM: 569815

RODGER COSTA RIOS - RM: 571438

RELATÓRIO DE ANÁLISE ESTATÍSTICA DA VULNERABILIDADE SOCIAL NOS MUNICÍPIOS BRASILEIROS:

Análise de dados municipais aplicada ao desenvolvimento de soluções de apoio ao cidadão

Trabalho Acadêmico apresentado à Faculdade de Informática e Administração Paulista - FIAP, como requisito parcial para obtenção de nota na disciplina de Modelagem Linear para Aprendizado de Máquina. Orientador: Prof. André Tritiack de Farias.

SÃO PAULO

2026

SUMÁRIO

1. INTRODUÇÃO....4
1.1 Delimitação do problema....4
1.2 Objetivo do relatório....5
1.3 Justificativa....5
2. SELEÇÃO E JUSTIFICATIVA DA BASE DE DADOS....7
2.1 Fonte dos dados....7
2.2 Características da base de dados....7
2.3 Variáveis utilizadas....8
2.4 Estatísticas descritivas....9
3. PROCEDIMENTOS METODOLÓGICOS....10
3.1 Ferramentas utilizadas....10
3.2 Preparação dos dados....10
3.3 Métodos estatísticos....10
4. RESULTADOS E INTERPRETAÇÃO....13
4.1 Distribuição da vulnerabilidade social....13
4.2 Testes de hipótese para a média....14
4.3 Relação entre analfabetismo e vulnerabilidade social....15
4.4 Regressão linear múltipla....17
4.4.1 Matrizes de covariância e de correlação....18
4.4.2 Equação da regressão linear múltipla....20
4.4.3 Adequação do modelo....21
4.4.4 Previsão....21
4.5 Regressão logística binária....22
4.5.1 Equação da regressão logística....22
4.5.2 Matriz de confusão e acurácia....23
4.5.3 Classificação....24
5. RECOMENDAÇÕES....25
5.1 Onde implantar a solução....25
5.2 Como a solução deve funcionar....25
5.3 Como acompanhar e atualizar a análise....26
6. LIMITAÇÕES....27
7. CONCLUSÃO....29
8. REFERÊNCIAS BIBLIOGRÁFICAS....30

1. INTRODUÇÃO

O acesso a informações sobre serviços públicos, documentos e direitos é uma condição básica para que os cidadãos possam exercer sua cidadania. Na prática, porém, esse acesso não é igual para todos: pessoas com menor escolaridade, renda instável ou que vivem em locais com infraestrutura precária tendem a enfrentar mais dificuldades para encontrar e compreender essas informações, justamente por serem, muitas vezes, as que mais dependem delas.

Esse cenário se relaciona com o desafio *Citizen Tech*, que propõe o desenvolvimento de soluções tecnológicas baseadas nas necessidades reais das pessoas, com o objetivo de melhorar a vida nas cidades, no campo e nas comunidades. Entre os casos norteadores do desafio está o *Citizen Assist AI*, um assistente digital que facilita o acesso dos cidadãos a informações úteis do cotidiano, como serviços, documentos, direitos e orientações comunitárias.

Para que uma solução desse tipo gere impacto, é necessário saber onde ela é mais necessária e quais características da população ela deve considerar. Este relatório contribui para essa decisão por meio da análise estatística de dados reais dos municípios brasileiros, utilizando a vulnerabilidade social como indicador da necessidade de apoio ao cidadão.

1.1 Delimitação do problema

Embora a vulnerabilidade social seja amplamente reconhecida como um obstáculo ao acesso a direitos e serviços, sua intensidade varia de forma expressiva entre os municípios brasileiros. Segundo os dados do Atlas do Desenvolvimento Humano no Brasil, referentes ao Censo Demográfico de 2010, a proporção da população vulnerável à pobreza variava de cerca de 2% a mais de 90% entre os municípios do país, com média de aproximadamente 44%. Ou seja, em parte do território nacional, a vulnerabilidade atingia uma pequena parcela dos habitantes; em outra, a ampla maioria da população.

Diante dessa desigualdade, uma solução de apoio ao cidadão não pode ser implantada da mesma forma em todo o país. Contudo, ainda não está claro quais características dos municípios estão mais associadas à vulnerabilidade, nem qual critério objetivo poderia ser usado para identificar onde essa solução deve chegar primeiro. Sem essas informações, a priorização tende a ser baseada em percepções, e não em evidências.

Assim, a questão que motivou este estudo estatístico é:

Quais fatores socioeconômicos se associam à vulnerabilidade social nos municípios brasileiros, e como esses resultados podem orientar onde priorizar uma solução de apoio ao cidadão?

1.2 Objetivo do relatório

O objetivo geral deste relatório é identificar os fatores socioeconômicos associados à vulnerabilidade social nos municípios brasileiros e estabelecer um critério estatístico para priorizar a implantação de uma solução de apoio ao cidadão.

Para isso, busca-se descrever a distribuição da vulnerabilidade entre os municípios e verificar se amostras aleatórias representam a média nacional. Em seguida, pretende-se medir a relação da vulnerabilidade com o analfabetismo, o grau de formalização do trabalho e o acesso a saneamento básico, por meio de modelos de regressão linear. Por fim, objetiva-se classificar os municípios como prioritários ou não, por meio da regressão logística, e avaliar a precisão dessa classificação.

1.3 Justificativa

A implantação de uma solução de apoio ao cidadão envolve recursos limitados, o que exige decidir onde ela deve começar e para qual público deve ser pensada. Este relatório se destina a gestores públicos, desenvolvedores de soluções tecnológicas e demais interessados nessa decisão, e oferece a eles uma base objetiva para fazer essas escolhas.

A estatística aplicada contribui para a tomada de decisão em três aspectos. Primeiro, permite identificar quais fatores caminham junto com a vulnerabilidade, indicando as barreiras que a solução precisa considerar, como a baixa alfabetização da população. Segundo, os modelos de regressão permitem estimar o nível de vulnerabilidade de um município a partir de características conhecidas, mesmo quando esse indicador não está disponível. Terceiro, a regressão logística oferece um critério para classificar os municípios como prioritários, substituindo escolhas baseadas em percepções por decisões fundamentadas em dados.

Além da relevância para a tomada de decisão, o estudo se relaciona com três Objetivos de Desenvolvimento Sustentável (ODS) da Agenda 2030 da ONU. Ao direcionar a solução aos municípios mais vulneráveis, contribui para o ODS 10 – Redução das desigualdades, especialmente para a meta 10.2, de inclusão social e econômica de todos. Ao evidenciar a relação entre analfabetismo e vulnerabilidade e propor uma solução acessível a pessoas com

baixa alfabetização, relaciona-se com o ODS 4 – Educação de qualidade, em particular com a meta 4.6, de alfabetização de jovens e adultos. Por fim, ao considerar o acesso a saneamento básico e facilitar o acesso da população a serviços públicos, conecta-se ao ODS 11 – Cidades e comunidades sustentáveis, especialmente à meta 11.1, de acesso de todos aos serviços básicos.

2. SELEÇÃO E JUSTIFICATIVA DA BASE DE DADOS

2.1 Fonte dos dados

Os dados utilizados neste estudo foram obtidos do Atlas do Desenvolvimento Humano no Brasil, plataforma desenvolvida pelo Programa das Nações Unidas para o Desenvolvimento (PNUD), pelo Instituto de Pesquisa Econômica Aplicada (Ipea) e pela Fundação João Pinheiro (FJP). O Atlas reúne indicadores de desenvolvimento humano, educação, renda, trabalho, habitação e vulnerabilidade para todos os municípios brasileiros, calculados a partir dos Censos Demográficos do Instituto Brasileiro de Geografia e Estatística (IBGE).

A base foi obtida na seção "Acervo – Biblioteca" da plataforma (disponível em: https://www.atlasbrasil.org.br/acervo/biblioteca), no conjunto de dados "Censo Demográfico (1991, 2000 e 2010)", em formato .xlsx, com acesso em 9 de novembro de 2026.

A escolha dessa fonte se justifica por três motivos: trata-se de dados reais e oficiais, produzidos por instituições reconhecidas; a base cobre todos os municípios do país; e reúne, em um único arquivo, diversos indicadores numéricos relacionados à vulnerabilidade social, o que permite aplicar as técnicas estatísticas propostas sem a necessidade de combinar diferentes fontes.

2.2 Características da base de dados

O arquivo original contém 16.695 registros e 237 variáveis, correspondentes aos 5.565 municípios brasileiros existentes em 2010, observados em três anos: 1991, 2000 e 2010.

Neste estudo, foram utilizados apenas os dados de 2010. A escolha se justifica, em primeiro lugar, por esse ser o período de referência mais recente para o qual o Atlas disponibiliza o conjunto completo de indicadores por município. Durante a seleção da base, foram consideradas fontes mais atuais, mas nenhuma atendia às necessidades do estudo: a atualização do Índice de Vulnerabilidade Social (IVS), elaborada pelo Ipea com dados de 2022, apresenta resultados apenas para o país e para os estados, e não por município; já a utilização do Censo Demográfico de 2022 exigiria a combinação de diversas tabelas, sem a garantia de que os indicadores de renda e vulnerabilidade estivessem disponíveis para todos os municípios. Além disso, o uso de uma única fonte e de um único ano garante que todas as variáveis tenham sido produzidas com a mesma metodologia e se refiram ao mesmo

momento, o que permite compará-las e relacioná-las de forma consistente. A defasagem temporal desses dados é reconhecida e discutida na Seção 6, de limitações.

Assim, a base analisada é composta por 5.565 registros, um para cada município. Como todos os municípios do país estão incluídos, ela representa a população completa de municípios brasileiros em 2010, e não apenas uma amostra. Não foram encontrados valores ausentes nem registros duplicados nas variáveis selecionadas.

2.3 Variáveis utilizadas

Entre os indicadores disponíveis, foram selecionadas as variáveis apresentadas na Tabela 1.

Tabela 1 - Variáveis utilizadas na análise

Sigla	Descrição	Papel na análise
PPOB	Percentual da população vulnerável à pobreza	Variável principal (resposta)
T_ANALF18M	Taxa de analfabetismo da população de 18 anos ou mais (%)	Explicativa
P_FORMAL	Grau de formalização do trabalho das pessoas ocupadas (%)	Explicativa
T_BANAGUA	Percentual da população em domicílios com banheiro e água encanada	Explicativa
PRIORITARIO	1 se PPOB ≥ 50%; 0 caso contrário	Variável binária (regressão logística)

Fonte: elaborado pelos autores, com base em PNUD, Ipea e FJP (2013).

O PPOB foi escolhido como variável principal por medir diretamente a vulnerabilidade social. Segundo o Atlas, é considerada vulnerável à pobreza a pessoa que vive em domicílio com renda per capita igual ou inferior a R$ 255,00 mensais, valor equivalente a meio salário mínimo em agosto de 2010. As variáveis explicativas representam três dimensões associadas à vulnerabilidade: educação (analfabetismo), trabalho (formalização) e infraestrutura domiciliar (saneamento). A variável PRIORITARIO foi criada pelos autores a partir do PPOB, conforme descrito na Seção 3.

2.4 Estatísticas descritivas

A Tabela 2 apresenta as principais medidas das variáveis analisadas.

Tabela 2 - Estatísticas descritivas das variáveis (municípios, 2010)

Variável	Média	Desvio padrão	Mínimo	Mediana	Máximo
PPOB (%)	43,99	22,44	1,97	42,23	91,57
Analfabetismo (%)	17,40	10,70	0,97	14,11	47,64
Trabalho formal (%)	43,51	19,27	2,97	42,85	89,11
Saneamento (%)	80,87	21,71	3,26	91,25	100,00

Fonte: elaborado pelos autores, com base em PNUD, Ipea e FJP (2013).

Os dados mostram grande variação entre os municípios em todas as variáveis. No PPOB, o desvio padrão de 22,44 pontos percentuais, valor próximo da metade da média, indica que os municípios brasileiros apresentavam realidades muito distintas quanto à vulnerabilidade. No saneamento, a mediana (91,25%) é bem superior à média (80,87%), o que mostra que a maioria dos municípios tinha alta cobertura, enquanto uma parcela menor apresentava valores muito baixos, reduzindo a média. Em relação à variável PRIORITARIO, 2.415 municípios (43,4%) foram classificados como prioritários, ou seja, tinham metade ou mais da população vulnerável à pobreza, enquanto 3.150 (56,6%) foram classificados como não prioritários.

3. PROCEDIMENTOS METODOLÓGICOS

3.1 Ferramentas utilizadas

A análise foi desenvolvida na linguagem Python, no ambiente Google Colab, e organizada em dois notebooks: o primeiro dedicado à preparação dos dados e o segundo às análises estatísticas. Foram utilizadas as seguintes bibliotecas: pandas, para leitura e organização dos dados; NumPy e SciPy, para cálculos numéricos e estatísticos; Matplotlib e Seaborn, para a construção dos gráficos; e scikit-learn, para o ajuste dos modelos de regressão. Todos os procedimentos estão registrados nos notebooks, de modo que a análise pode ser reproduzida integralmente a partir da base original.

3.2 Preparação dos dados

A preparação dos dados seguiu as seguintes etapas:

1. Leitura da planilha original do Atlas, sem alterações no arquivo baixado;
2. Filtro dos registros referentes ao ano de 2010;
3. Seleção das variáveis de identificação dos municípios (código, nome e unidade da federação) e das variáveis de análise;
4. Verificação de valores ausentes e de registros duplicados, não sendo encontrada nenhuma ocorrência;
5. Criação da variável binária PRIORITARIO, que recebe valor 1 quando o PPOB é igual ou superior a 50% e valor 0 nos demais casos;
6. Exportação da base tratada em formato .csv, utilizada nas análises seguintes.

3.3 Métodos estatísticos

As técnicas foram aplicadas na sequência descrita a seguir.

Distribuição Normal de probabilidade: assumindo-se que o PPOB segue uma Distribuição Normal, foram calculadas a probabilidade de um município apresentar PPOB inferior à média e a probabilidade de apresentar PPOB superior à mediana, que é o valor que divide os municípios, ordenados, em duas metades. Utilizou-se o desvio padrão populacional, uma vez que a base contém todos os municípios do país. Os resultados foram classificados em quatro categorias: raro (até 10%), pouco provável (acima de 10% e abaixo de 50%), provável (de 50% a 90%) e quase certo (acima de 90%).

Testes de hipóteses para a média: um teste de hipóteses verifica se a diferença entre a média de uma amostra e uma média de referência é grande o suficiente para não ser explicada pelo acaso. Os 5.565 municípios foram considerados a população de referência, e foram sorteadas duas amostras aleatórias, de 20 e de 25 municípios, com semente fixa (random_state = 42), para garantir a reprodutibilidade. Aplicou-se o teste Z, adequado quando o desvio padrão populacional é conhecido. O primeiro teste verificou se a média da amostra era menor que a média populacional, ao nível de significância de 6%, e o segundo, se era maior, ao nível de 9%. O nível de significância é o risco aceito de concluir que existe diferença quando ela não existe. A hipótese nula é rejeitada quando a estatística Z ultrapassa o valor crítico ou, de forma equivalente, quando o p-valor, que é a probabilidade de se observar a diferença encontrada apenas por acaso, é menor que o nível de significância.

Análise bivariada e regressão linear simples: a relação entre o analfabetismo e o PPOB foi analisada por meio do gráfico de dispersão, da covariância, que indica a direção da relação, e da correlação de Pearson (r), que mede sua força em uma escala de −1 a +1. Em seguida, ajustou-se uma regressão linear simples, que descreve a relação média entre as variáveis por meio de uma reta. A adequação do modelo foi avaliada pelo coeficiente de determinação (R^2), que indica a proporção da variação do PPOB explicada pelo modelo, e pelo teste F, que verifica se o modelo é estatisticamente significativo, ao nível de 5%.

Regressão linear múltipla: o PPOB foi estimado a partir de três variáveis explicativas simultaneamente: analfabetismo, grau de formalização do trabalho e acesso a banheiro e água encanada. As relações entre as variáveis foram analisadas pelas matrizes de covariância e de correlação, e o modelo foi avaliado pelos mesmos critérios da regressão simples.

Regressão logística binária: a variável PRIORITARIO foi estimada a partir das mesmas três variáveis explicativas. Para avaliar o modelo em municípios não utilizados no seu ajuste, a base foi dividida em 70% dos municípios para treino e 30% para teste, mantendo-se nos dois grupos a mesma proporção de municípios prioritários. O desempenho foi avaliado pela matriz de confusão, que compara a classificação real com a prevista pelo modelo, e pela acurácia, que é a proporção de classificações corretas, comparada a uma acurácia de referência, obtida ao classificar todos os municípios na categoria mais frequente.

Previsões e classificação: em todos os modelos de regressão, utilizou-se um mesmo município hipotético, com 20% de analfabetismo, 40% de trabalho formal e 80% da população com

banheiro e água encanada, valores próximos das médias nacionais. Na regressão simples, considerou-se apenas a taxa de analfabetismo de 20%.

4. RESULTADOS E INTERPRETAÇÃO

4.1 Distribuição da vulnerabilidade social

Para descrever como a vulnerabilidade se distribui entre os municípios, assumiu-se que o PPOB segue uma Distribuição Normal, com média de 43,99% e desvio padrão de 22,44 pontos percentuais. A Tabela 3 apresenta as probabilidades calculadas.

Tabela 3 - Probabilidades calculadas pela Distribuição Normal

Evento	Probabilidade	Classificação
PPOB menor que a média (43,99%)	50,00%	Provável
PPOB maior que a mediana (42,23%)	53,13%	Provável

Fonte: elaborado pelos autores

A probabilidade de um município apresentar PPOB inferior à média foi de 50,00%. Esse resultado decorre de uma propriedade da Distribuição Normal: por ser simétrica, a média fica exatamente no centro da curva, dividindo os valores em duas partes iguais. Assim, um município escolhido ao acaso tem a mesma chance de estar acima ou abaixo da média nacional de vulnerabilidade.

A probabilidade de um município apresentar PPOB superior à mediana foi de 53,13%. A mediana é o valor que divide os municípios, ordenados do menor para o maior PPOB, em duas metades. Na base real, a mediana (42,23%) é um pouco menor que a média, e, por isso, o modelo normal estima uma chance ligeiramente superior a 50%. Nos dados reais, porém, essa proporção é exatamente 50%, pois metade dos municípios está, por definição, acima da mediana.

Essa diferença indica que a Distribuição Normal é apenas uma aproximação do comportamento real dos dados, o que pode ser observado na Figura 1.

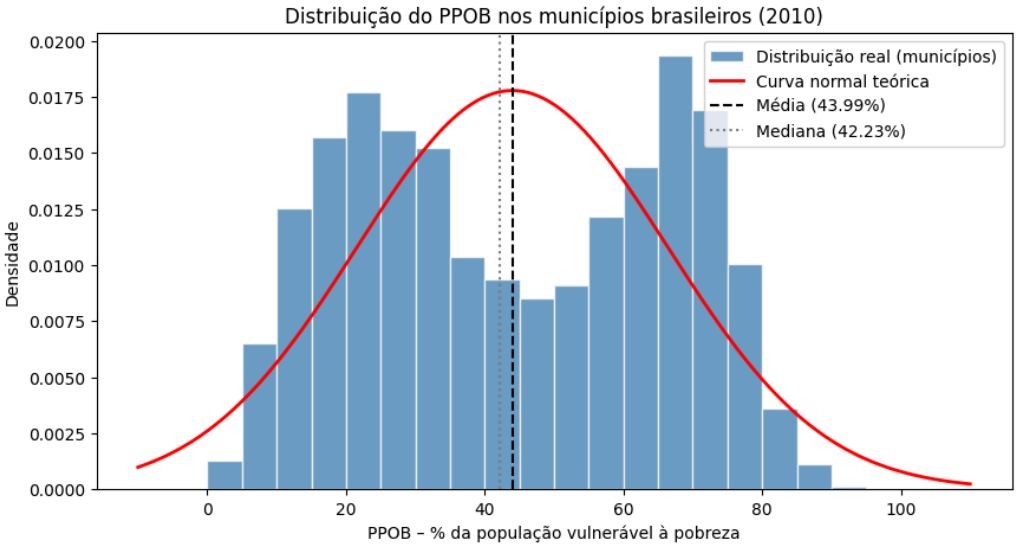


Figura 1: Distribuição do PPOB nos municípios brasileiros e curva normal teórica (2010)

Fonte: elaborado pelos autores, com base em PNUD, Ipea e FJP (2013)

Em vez do formato de sino da curva normal, a distribuição real apresenta dois picos, um próximo de 20–25% e outro próximo de 65–70%, separados por um vale próximo da média. Isso indica que os municípios brasileiros se dividiam, em 2010, em dois grandes grupos: um de menor e outro de maior vulnerabilidade.

Para o problema estudado, esse resultado mostra que a média nacional não representa bem a realidade da maioria dos municípios. Assim, uma solução de apoio ao cidadão não deve ser planejada a partir de um "município médio", mas considerar a existência de realidades muito distintas, o que reforça a necessidade de um critério de priorização.

4.2 Testes de hipótese para a média

Em ambos os testes, a hipótese nula (H_0) considerou que a média do PPOB na amostra era igual à média populacional de 43,99%. A hipótese alternativa (H_1) considerou que ela era menor, no primeiro teste, e maior, no segundo. A Tabela 4 apresenta os resultados.

Tabela 4 - Resultados dos testes de hipóteses para a média do PPOB

	Teste 1	**Teste 2**
Hipótese alternativa (H_1)	Média menor que 43,99%	Média maior que 43,99%
Tamanho da amostra	20 municípios	25 municípios
Nível de significância	6%	9%

Média da amostra	43,61%	44,13%
Estatística Z	−0,08	0,03
Valor crítico	−1,55	1,34
p-valor	0,47	0,49
Decisão	Não se rejeita H_0	Não se rejeita H_0

Fonte: elaborado pelos autores

Nos dois testes, as médias amostrais ficaram muito próximas da média populacional, e os p-valores (0,47 e 0,49) foram muito superiores aos respectivos níveis de significância. Portanto, não há evidência estatística de que a média das amostras seja menor ou maior que a média nacional: as pequenas diferenças observadas são compatíveis com a variação natural de um sorteio.

Para o problema estudado, cabe uma ressalva: não rejeitar a hipótese nula não significa que as médias sejam iguais, mas apenas que as diferenças observadas não foram grandes o suficiente para serem consideradas estatisticamente significativas. Além disso, amostras desse tamanho são pouco precisas: com 20 municípios, o erro padrão da média é de aproximadamente 5 pontos percentuais, o que significa que a média de uma amostra pode se afastar cerca de 10 pontos da média nacional apenas por acaso. Assim, os resultados indicam que o sorteio aleatório produziu amostras sem desvios sistemáticos em relação à média nacional, mas que amostras pequenas não seriam suficientes para estimar com precisão o nível de vulnerabilidade do país.

4.3 Relação entre analfabetismo e vulnerabilidade social

Nesta etapa, analisou-se a relação entre a taxa de analfabetismo da população de 18 anos ou mais e o PPOB, com o objetivo de verificar se municípios com mais analfabetismo tendem a apresentar maior vulnerabilidade social. A Figura 2 apresenta o gráfico de dispersão, em que cada ponto representa um município, com a reta de regressão ajustada.

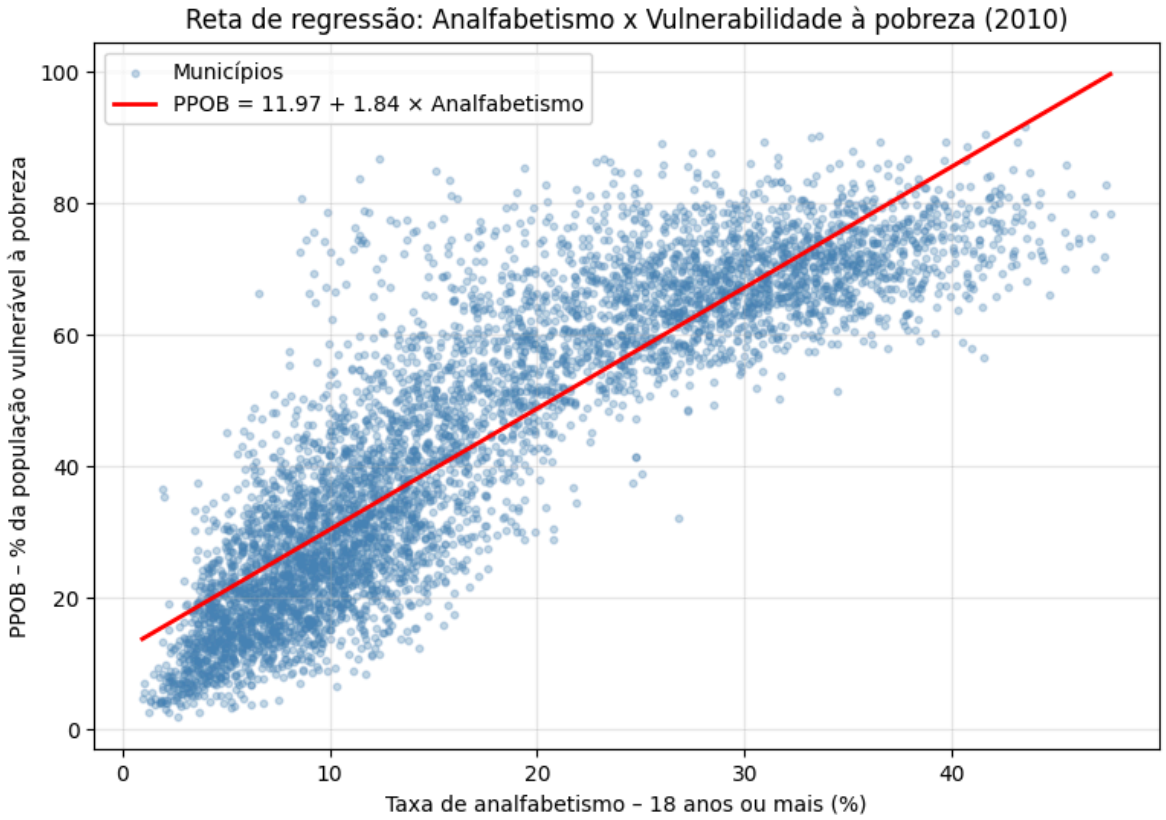


Figura 2: Relação entre analfabetismo e PPOB nos municípios brasileiros, com reta de regressão linear simples (2010)

Fonte: elaborado pelos autores, com base no PNUD, Ipea e FJP (2013)

Os pontos formam uma faixa crescente e concentrada em torno da reta, o que indica uma relação linear positiva entre as variáveis: quanto maior a taxa de analfabetismo, maior tende a ser a proporção da população vulnerável à pobreza. A covariância positiva (210,61) confirma que as variáveis variam no mesmo sentido, e a correlação de Pearson de r = 0,88 indica que essa relação é forte.

A equação da regressão linear simples obtida foi:

$$PPOB = 11,97 + 1,84 \times Analfabetismo$$

O coeficiente angular indica que, a cada aumento de 1 ponto percentual na taxa de analfabetismo, o PPOB aumenta, em média, 1,84 ponto percentual. O intercepto (11,97) corresponde ao PPOB estimado para um município sem analfabetismo; como nenhum município apresenta taxa nula, ele não tem interpretação prática direta. A Tabela 5 apresenta as medidas de adequação do modelo.

Tabela 5 - Medidas de adequação da regressão linear simples

Medida	Valor
R^2	0,7697 (76,97%)
Estatística F	18.588,16
p-valor do teste F	< 0,0001

Fonte: elaborado pelos autores

O R^2 indica que cerca de 77% da variação do PPOB entre os municípios é explicada pela taxa de analfabetismo, e o p-valor do teste F, inferior a 0,0001, mostra que o modelo é estatisticamente significativo.

Observa-se, no entanto, que a relação não é perfeitamente linear: nos municípios com analfabetismo acima de cerca de 30%, os pontos tendem a ficar abaixo da reta. Assim, o modelo tende a superestimar a vulnerabilidade nos municípios com analfabetismo muito elevado.

Para o município hipotético com 20% de analfabetismo, o modelo estimou um PPOB de 48,77%, ligeiramente abaixo do limite de 50% que define um município prioritário. Pela equação, esse limite é atingido quando o analfabetismo chega a aproximadamente 20,7%. Assim, municípios com analfabetismo acima desse patamar tendem a ser prioritários.

Para a solução de apoio ao cidadão, esse resultado tem uma implicação direta: nos municípios que mais precisam dela, uma parcela significativa da população adulta não sabe ler nem escrever. Por isso, a solução deve oferecer recursos acessíveis a pessoas com baixa alfabetização, como linguagem simples e orientações por áudio.

4.4 Regressão linear múltipla

Nesta etapa, o PPOB foi analisado em conjunto com três fatores, que representam as dimensões de educação, trabalho e infraestrutura domiciliar: a taxa de analfabetismo, o grau de formalização do trabalho e o percentual da população em domicílios com banheiro e água encanada. O objetivo foi verificar se a combinação desses fatores explica melhor a vulnerabilidade do que o analfabetismo isoladamente. A Figura 3 apresenta a relação de cada um deles com o PPOB.

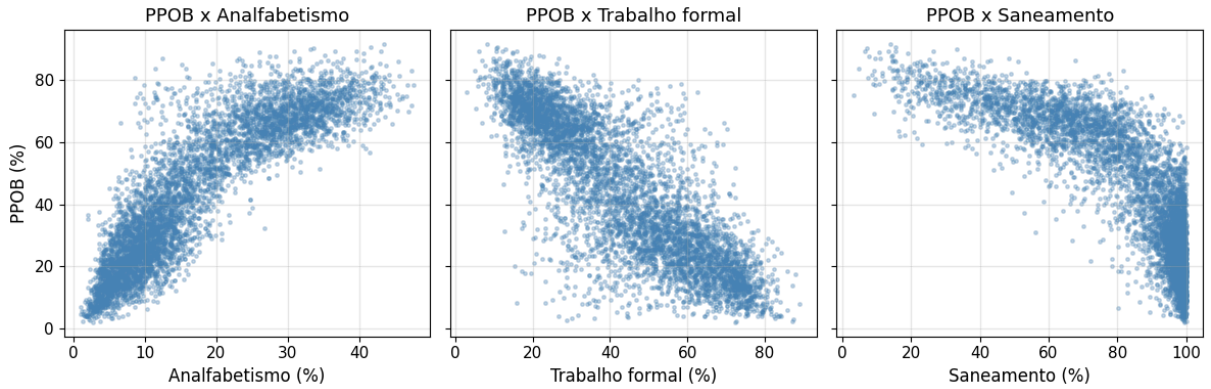


Figura 3: Relação entre o PPOB e as variáveis explicativas nos municípios brasileiros (2010)
Fonte: elaborado pelos autores, com base em PNUD, Ipea e FJP (2013)

Os gráficos mostram que as três variáveis têm relação visível com o PPOB. No caso do analfabetismo, os pontos sobem da esquerda para a direita, indicando uma relação positiva. Já no trabalho formal e no saneamento, os pontos descem, indicando relações negativas: quanto maior a formalização do trabalho e o acesso a banheiro e água encanada, menor tende a ser a vulnerabilidade. No saneamento, os pontos se concentram à direita, pois a maioria dos municípios apresentava alta cobertura; os municípios com pior saneamento, em geral, apresentavam vulnerabilidade elevada.

4.4.1 Matrizes de covariância e de correlação

As Tabelas 6 e 7 apresentam, respectivamente, as matrizes de covariância e de correlação de Pearson entre as variáveis do modelo.

Tabela 6 - Matriz de covariância

	PPOB	Analfabetismo	Trabalho formal	Saneamento
PPOB	503,46	210,61	−360,57	−400,17
Analfabetismo	210,61	114,47	−159,12	−173,81
Trabalho formal	−360,57	−159,12	371,53	302,29
Saneamento	−400,17	−173,81	302,29	471,43

Fonte: elaborado pelos autores

Tabela 7 - Matriz de correlação de Pearson

	PPOB	Analfabetismo	Trabalho formal	Saneamento
PPOB	1,00	0,88	−0,83	−0,82
Analfabetismo	0,88	1,00	−0,77	−0,75
Trabalho formal	−0,83	−0,77	1,00	0,72
Saneamento	−0,82	−0,75	0,72	1,00

Fonte: elaborado pelos autores

A matriz de covariância confirma a direção das relações: o analfabetismo varia no mesmo sentido do PPOB, enquanto o trabalho formal e o saneamento variam em sentido oposto. Como seus valores dependem das unidades das variáveis, a força das relações é analisada pela matriz de correlação. Na matriz de correlação, as três variáveis explicativas apresentam correlação forte com o PPOB: 0,88 para o analfabetismo, −0,83 para o trabalho formal e −0,82 para o saneamento. As variáveis explicativas também são fortemente correlacionadas entre si, com valores entre 0,72 e 0,77, em módulo. Isso indica que educação, trabalho e infraestrutura tendem a ocorrer juntos nos municípios: aqueles com mais analfabetismo costumam ter menos trabalho formal e pior saneamento. A Figura 4 apresenta essas relações.

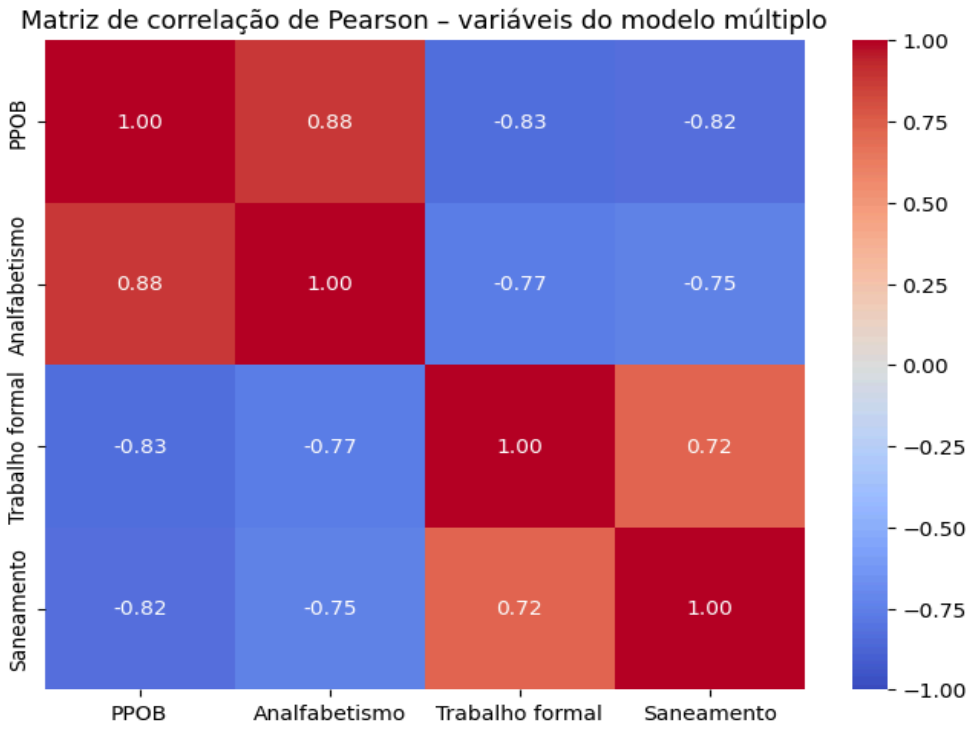


Figura 4: Matriz de correlação de Pearson entre as variáveis do modelo múltiplo

Fonte: elaborado pelos autores, com base em PNUD, Ipea e FJP (2013)

No mapa de calor, os tons intensos de vermelho e azul em toda a matriz confirmam que todas as variáveis estão fortemente relacionadas, tanto com o PPOB quanto entre si. Por esse motivo, os coeficientes da regressão múltipla devem ser interpretados com cautela, pois parte do efeito de cada variável é compartilhada com as demais.

4.4.2 Equação da regressão linear múltipla

A equação obtida foi:

$$PPOB = 65,67 + 0,94 \times Analfabetismo - 0,33 \times Trabalho\ formal - 0,29 \times Saneamento$$

Cada coeficiente indica a variação média do PPOB quando a variável correspondente aumenta 1 ponto percentual, mantidas as demais constantes. O analfabetismo aumenta a vulnerabilidade, enquanto o trabalho formal e o saneamento a reduzem, o que é coerente com os gráficos de dispersão.

O coeficiente do analfabetismo caiu de 1,84, na regressão simples, para 0,94, na regressão múltipla. Isso ocorre porque, no modelo simples, o analfabetismo também captava parte da influência do trabalho formal e do saneamento, com os quais está relacionado. Ao incluir

essas variáveis no modelo, essa influência passa a ser atribuída a cada uma delas. A Tabela 8 compara as medidas de adequação dos modelos simples e múltiplo.

4.4.3 Adequação do modelo

Tabela 8 - Medidas de adequação das regressões lineares simples e múltipla

Medida	Regressão simples	Regressão múltipla
R^2	0,7697 (76,97%)	0,8609 (86,09%)
Estatística F	18.588,16	11.472,13
p-valor do teste F	< 0,0001	< 0,0001

Fonte: elaborado pelos autores

O R^2 de 0,86 indica que cerca de 86% da variação do PPOB é explicada pelo conjunto das três variáveis, contra 77% no modelo com apenas o analfabetismo. A inclusão do trabalho formal e do saneamento, portanto, melhorou a capacidade do modelo de explicar a vulnerabilidade. O teste F apresentou p-valor inferior a 0,0001, o que indica que o modelo é estatisticamente significativo.

Para o problema estudado, esse resultado mostra que a vulnerabilidade social não se explica por um único fator, mas pela combinação de condições educacionais, de trabalho e de infraestrutura. Ressalta-se que os resultados indicam associação, e não causalidade.

4.4.4 Previsão

Para o mesmo município hipotético, com 20% de analfabetismo, 40% de trabalho formal e 80% da população com banheiro e água encanada, valores próximos das médias nacionais, o modelo estimou um PPOB de 47,84%. Esse valor está próximo do limite de 50%, e o município seria classificado como não prioritário.

O resultado mostra que municípios com características próximas da média nacional já se encontram no limite da vulnerabilidade. Para a solução de apoio ao cidadão, isso indica que não basta considerar a baixa alfabetização: a solução também deve incluir orientações sobre direitos trabalhistas, formalização do trabalho e acesso a serviços básicos, como saneamento.

4.5 Regressão logística binária

Enquanto as regressões lineares estimam o valor do PPOB, a regressão logística estima a probabilidade de um município pertencer a um determinado grupo. Neste estudo, ela foi utilizada para estimar a probabilidade de um município ser prioritário, isto é, de ter 50% ou mais da sua população vulnerável à pobreza. Quando essa probabilidade é igual ou superior a 50%, o município é classificado como prioritário; caso contrário, como não prioritário.

Foram utilizadas as mesmas variáveis explicativas da regressão linear múltipla: analfabetismo, trabalho formal e saneamento. O PPOB não foi incluído como variável explicativa, pois a variável PRIORITARIO foi criada a partir dele, o que tornaria a classificação trivial.

Para avaliar se o modelo é capaz de classificar corretamente municípios que não foram utilizados no seu ajuste, a base foi dividida em dois grupos: 70% dos municípios (3.895) para treino, utilizados no ajuste do modelo, e 30% (1.670) para teste, utilizados na avaliação.

4.5.1 Equação da regressão logística

A regressão logística é composta por duas etapas. Primeiro, as variáveis explicativas são combinadas em um valor z:

$$z = 6,5569 + 0,3593 \times Analfabetismo - 0,0506 \times Trabalho\ formal - 0,1270 \times Saneamento$$

Em seguida, esse valor é transformado em uma probabilidade entre 0 e 1 pela função logística:

$$P(prioritário) = 1 / (1 + e\text{^}(- z))$$

Os sinais dos coeficientes indicam como cada variável influencia a probabilidade de o município ser prioritário, mantidas as demais constantes. O analfabetismo, com coeficiente positivo, aumenta essa probabilidade, enquanto o trabalho formal e o saneamento, com coeficientes negativos, a reduzem. Esses resultados são coerentes com os obtidos na regressão linear múltipla.

4.5.2 Matriz de confusão e acurácia

A matriz de confusão compara a classificação real de cada município do grupo de teste com a classificação feita pelo modelo, permitindo identificar não apenas quantos acertos houve, mas também quais tipos de erro ocorreram. A Figura 5 apresenta o resultado.

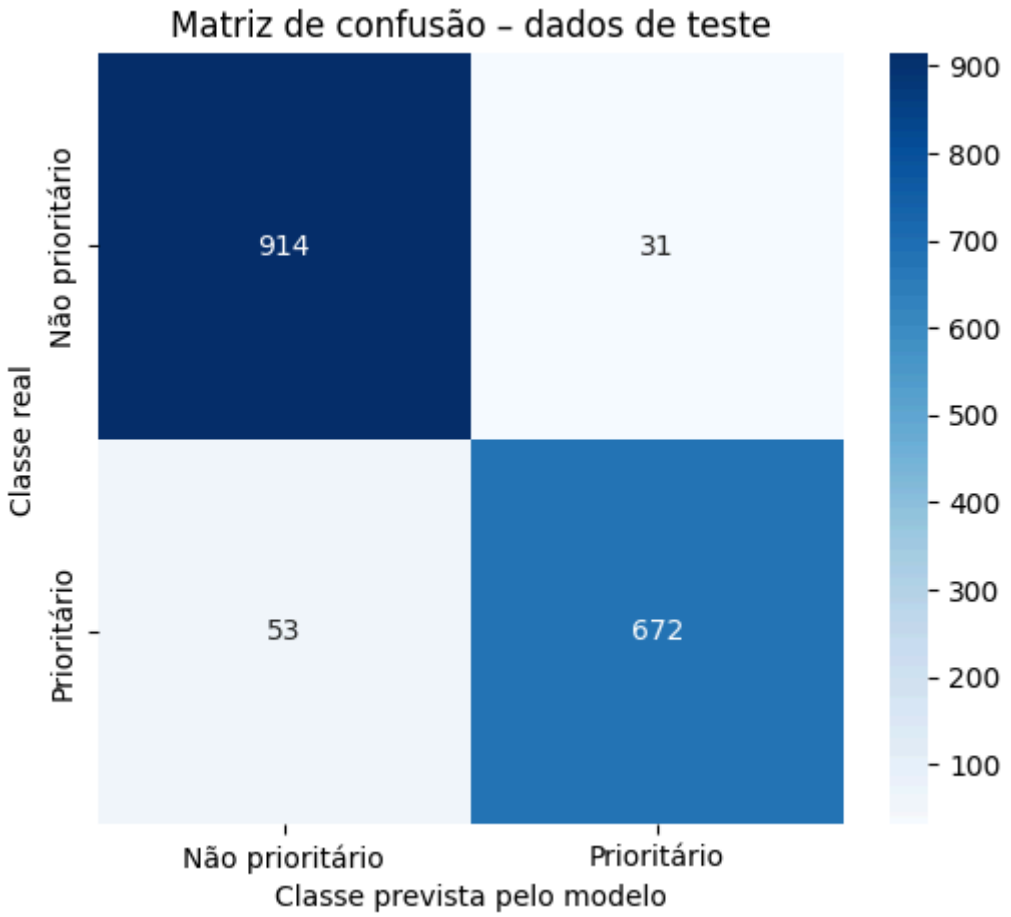


Figura 5: Matriz de confusão da regressão logística, com os dados de teste

Fonte: elaborado pelos autores com base em PNUD, Ipea e FJP (2013)

Dos 1.670 municípios do grupo de teste:

- 914 municípios não prioritários foram classificados corretamente;
- 672 municípios prioritários foram classificados corretamente;
- 31 municípios não prioritários foram classificados, por engano, como prioritários;
- 53 municípios prioritários foram classificados, por engano, como não prioritários.

A acurácia, que corresponde à proporção de classificações corretas, foi de 94,97%, ou seja, 1.586 acertos em 1.670 municípios. Para avaliar se esse valor é de fato elevado, ele foi

comparado a uma acurácia de referência: se todos os municípios fossem classificados como não prioritários, que é a categoria mais frequente, a taxa de acerto seria de 56,59%. Como o modelo supera amplamente esse valor, conclui-se que ele apresenta bom desempenho na identificação dos municípios prioritários.

Os dois tipos de erro, porém, não têm o mesmo impacto para o problema estudado. Classificar como prioritário um município que não é, como ocorreu em 31 casos, levaria a solução a um local com menor necessidade. Já deixar de identificar um município prioritário, como ocorreu em 53 casos, significaria não atender uma população que precisa da solução. Por isso, o segundo tipo de erro é o mais grave. Em uma aplicação real, pode ser preferível aceitar mais classificações equivocadas como prioritário para reduzir o número de municípios vulneráveis não identificados.

4.5.3 Classificação

Para a classificação, utilizou-se o mesmo município hipotético das regressões lineares, com 20% de analfabetismo, 40% de trabalho formal e 80% da população com banheiro e água encanada. Optou-se por esse município, em vez de exemplos com perfis claramente opostos, para permitir a comparação entre os modelos.

O modelo estimou uma probabilidade de 82,63% de esse município ser prioritário, classificando-o, portanto, como prioritário. Esse resultado difere do obtido na regressão linear múltipla, que estimou um PPOB de 47,84%, ligeiramente abaixo do limite de 50%, e o classificaria como não prioritário.

A divergência ocorre porque o município está muito próximo da fronteira entre os dois grupos, e os modelos funcionam de formas diferentes: a regressão linear estima o valor médio do PPOB para municípios com aquelas características, enquanto a regressão logística é ajustada especificamente para separar os municípios prioritários dos não prioritários. Em casos distantes da fronteira, espera-se que os modelos concordem; nos casos próximos ao limite, pequenas diferenças entre eles podem alterar a classificação.

Para o problema estudado, essa divergência traz uma conclusão importante: a priorização de municípios próximos ao limite de 50% não deve depender de um único modelo. Recomenda-se que esses casos de fronteira recebam uma análise complementar, com dados locais mais recentes, antes da decisão sobre a implantação da solução.

5. RECOMENDAÇÕES

Com base nos resultados obtidos, são apresentadas as seguintes recomendações para a implantação de uma solução de apoio ao cidadão, como o *Citizen Assist AI*.

5.1 Onde implantar a solução

Priorizar os municípios com metade ou mais da população vulnerável à pobreza. Pelo critério adotado neste estudo, 2.415 municípios (43,4% do total) se enquadravam nessa condição em 2010. A implantação deve começar por esses territórios, para que a solução alcance primeiro a população que mais depende de orientação sobre serviços e direitos.

Utilizar indicadores de educação, trabalho e infraestrutura para identificar municípios prioritários. A regressão logística classificou corretamente cerca de 95% dos municípios a partir do analfabetismo, do grau de formalização do trabalho e do acesso a banheiro e água encanada. Assim, esses indicadores podem apoiar a identificação de municípios prioritários mesmo quando o dado de vulnerabilidade não estiver disponível ou atualizado.

Tratar a taxa de analfabetismo próxima de 20% como sinal de alerta. Pela regressão simples, o limite de 50% de vulnerabilidade é atingido quando o analfabetismo chega a aproximadamente 20,7%. Municípios próximos ou acima desse patamar devem receber atenção especial no planejamento da implantação.

Analisar com cautela os municípios próximos ao limite de 50%. Como mostrou a comparação entre os modelos, municípios com características próximas da média nacional podem ser classificados de formas diferentes. Para esses casos de fronteira, recomenda-se uma análise complementar, com dados locais mais recentes, antes da decisão final.

5.2 Como a solução deve funcionar

Garantir acessibilidade a pessoas com baixa alfabetização. O analfabetismo foi o fator mais associado à vulnerabilidade. Por isso, a solução não deve depender apenas de textos: recomenda-se o uso de linguagem simples, orientações por áudio e navegação com ícones e poucas etapas.

Incluir conteúdos sobre trabalho e serviços básicos. A regressão múltipla mostrou que a vulnerabilidade está associada também à baixa formalização do trabalho e à falta de saneamento. Assim, além de informações sobre documentos e benefícios, a solução deve

oferecer orientações sobre direitos trabalhistas, formalização e acesso a serviços públicos básicos.

Não planejar a solução para um "município médio". A distribuição da vulnerabilidade mostrou dois grandes grupos de municípios, de menor e de maior vulnerabilidade. Portanto, conteúdos e estratégias de divulgação devem ser adaptados à realidade de cada grupo, em vez de seguir um modelo único para todo o país.

5.3 Como acompanhar e atualizar a análise

Atualizar a análise com dados mais recentes. Como os dados utilizados se referem a 2010, recomenda-se repetir a análise quando os indicadores municipais do Censo Demográfico de 2022 estiverem disponíveis no mesmo formato, verificando se as relações encontradas se mantêm.

Utilizar levantamentos por amostragem entre os Censos, com amostras maiores. Os testes de hipóteses não indicaram diferença significativa entre as médias de amostras aleatórias e a média nacional, o que sugere que o sorteio aleatório é uma forma adequada de selecionar municípios para acompanhamento. No entanto, como amostras de 20 ou 25 municípios apresentaram baixa precisão, levantamentos desse tipo devem utilizar amostras maiores para que possam apoiar decisões com segurança.

Ajustar o modelo para reduzir os municípios prioritários não identificados. Na regressão logística, o erro mais grave foi deixar de identificar 53 municípios prioritários. Em uma aplicação real, recomenda-se avaliar a redução do limite de probabilidade usado para classificar um município como prioritário, aceitando mais alarmes falsos em troca de menos municípios vulneráveis sem atendimento.

6. LIMITAÇÕES

Os resultados deste estudo devem ser interpretados considerando as seguintes limitações.

Defasagem temporal dos dados. As análises utilizaram dados de 2010, o período mais recente disponível por município na base do Atlas. Desde então, as condições socioeconômicas dos municípios podem ter mudado significativamente. Além disso, os municípios criados após 2010 não estão incluídos na base. Por isso, os resultados descrevem as relações observadas naquele momento e não devem ser interpretados como um retrato da situação atual.

A vulnerabilidade como medida aproximada da necessidade. O estudo utilizou o percentual da população vulnerável à pobreza como indicador da necessidade de apoio ao cidadão. Essa é uma aproximação: o PPOB é calculado a partir da renda e não mede diretamente a dificuldade da população em acessar informações sobre serviços e direitos.

A associação não implica causalidade. As correlações e os modelos de regressão mostram que analfabetismo, trabalho formal e saneamento estão associados à vulnerabilidade, mas não permitem afirmar que esses fatores a causam. As variáveis podem ser influenciadas por fatores comuns não incluídos no modelo, como a renda, a localização geográfica e o acesso a políticas públicas.

Dados agregados por município. As variáveis representam médias e percentuais de cada município, e não características individuais. Assim, os resultados descrevem padrões entre municípios e não podem ser aplicados diretamente a pessoas: um município classificado como não prioritário pode ter moradores em situação de alta vulnerabilidade.

Suposição de normalidade. As probabilidades foram calculadas assumindo que o PPOB segue uma Distribuição Normal. Como o histograma mostrou, a distribuição real apresenta dois picos e não segue o formato de sino da curva normal. Por isso, as probabilidades obtidas devem ser vistas como aproximações.

Forma linear dos modelos. Os modelos de regressão linear pressupõem que a relação entre as variáveis é representada por uma reta. Como observado na Figura 2, a relação entre analfabetismo e vulnerabilidade apresenta uma leve curvatura, o que faz o modelo superestimar a vulnerabilidade nos municípios com analfabetismo muito elevado.

Dependência das amostras sorteadas. Os testes de hipóteses foram realizados com uma única amostra para cada teste. Outras amostras, obtidas com sementes diferentes, poderiam gerar médias e conclusões diferentes, especialmente por se tratar de amostras pequenas.

Relação entre as variáveis explicativas. As variáveis explicativas são fortemente correlacionadas entre si, o que dificulta separar o efeito de cada uma. Por isso, os coeficientes da regressão múltipla e da regressão logística devem ser interpretados com cautela.

Critério de priorização. O limite de 50% de vulnerabilidade para definir um município prioritário foi escolhido por ser objetivo e de fácil interpretação, mas outros limites levariam a classificações diferentes. Além disso, os municípios próximos a esse limite podem ser classificados de formas distintas por diferentes modelos, como observado neste estudo.

Avaliação da regressão logística. O desempenho do modelo foi avaliado com uma única divisão entre os municípios de treino e de teste. Outras divisões poderiam resultar em valores de acurácia ligeiramente diferentes.

7. CONCLUSÃO

Este estudo buscou identificar os fatores socioeconômicos associados à vulnerabilidade social nos municípios brasileiros e estabelecer um critério estatístico para priorizar a implantação de uma solução de apoio ao cidadão.

Os resultados mostram que, em 2010, a vulnerabilidade social estava fortemente associada a condições de educação, trabalho e infraestrutura. O analfabetismo foi o fator mais relacionado à vulnerabilidade, explicando sozinho cerca de 77% da sua variação entre os municípios. Quando combinado ao grau de formalização do trabalho e ao acesso a banheiro e água encanada, essa proporção subiu para cerca de 86%. Esses mesmos fatores permitiram classificar corretamente cerca de 95% dos municípios como prioritários ou não prioritários, o que demonstra que podem ser utilizados como base objetiva para a priorização territorial.

Respondendo à pergunta que orientou o estudo, os resultados indicam que uma solução de apoio ao cidadão deve chegar primeiro aos municípios com metade ou mais da população vulnerável à pobreza, que, em geral, apresentam maior analfabetismo, menor formalização do trabalho e pior acesso a saneamento. Além disso, a solução deve ser pensada para esse público, com recursos acessíveis a pessoas com baixa alfabetização e conteúdos sobre direitos trabalhistas e serviços básicos.

Dessa forma, o estudo contribui para o desafio *Citizen Tech* ao transformar dados públicos em orientações práticas sobre onde e como implantar o *Citizen Assist AI*, em linha com os ODS 10, 4 e 11. A principal limitação é a defasagem dos dados de 2010. Por isso, recomenda-se que a análise seja atualizada com dados mais recentes, para confirmar se as relações encontradas se mantêm e para orientar com mais precisão as decisões atuais.

8. REFERÊNCIAS BIBLIOGRÁFICAS

FIAP. **Global Solution: CitizenTech**. São Paulo: FIAP, 2026. Disponível em: https://experience.fiap.com.br/global-solution-citizen-tech. Acesso em: 9 nov. 2026.

HARRIS, C. R. et al. Array programming with NumPy. **Nature**, v. 585, p. 357-362, 2020.

HUNTER, J. D. Matplotlib: a 2D graphics environment. **Computing in Science & Engineering**, v. 9, n. 3, p. 90-95, 2007.

INSTITUTO DE PESQUISA ECONÔMICA APLICADA (IPEA). **Atualização do Índice de Vulnerabilidade Social (IVS)**. Brasília: Ipea, [s.d.]. Disponível em: https://repositorio.ipea.gov.br/bitstreams/dd1c68b2-343e-4258-b65c-6079ce7b9bba/download. Acesso em: 6 nov. 2026.

INSTITUTO DE PESQUISA ECONÔMICA APLICADA (IPEA). **ODS 4: Educação de qualidade**. Brasília: Ipea, [s.d.]. Disponível em: https://ipea.gov.br/ods/ods4.html. Acesso em: 10 nov. 2026.

INSTITUTO DE PESQUISA ECONÔMICA APLICADA (IPEA). **ODS 10: Redução das desigualdades**. Brasília: Ipea, [s.d.]. Disponível em: https://ipea.gov.br/ods/ods10.html. Acesso em: 10 nov. 2026.

INSTITUTO DE PESQUISA ECONÔMICA APLICADA (IPEA). **ODS 11: Cidades e comunidades sustentáveis**. Brasília: Ipea, [s.d.]. Disponível em: https://ipea.gov.br/ods/ods11.html. Acesso em: 10 nov. 2026.

MCKINNEY, W. Data structures for statistical computing in Python. In: PYTHON IN SCIENCE CONFERENCE, 9., 2010, Austin. **Proceedings [...]**. Austin: SciPy, 2010. p. 56-61.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011.

PROGRAMA DAS NAÇÕES UNIDAS PARA O DESENVOLVIMENTO (PNUD); INSTITUTO DE PESQUISA ECONÔMICA APLICADA (IPEA); FUNDAÇÃO JOÃO PINHEIRO (FJP). **Atlas do Desenvolvimento Humano no Brasil: Censo Demográfico (1991, 2000 e 2010)**. Brasília: PNUD, 2013. Disponível em: https://www.atlasbrasil.org.br/acervo/biblioteca. Acesso em: 9 nov. 2026.

VIRTANEN, P. et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. **Nature Methods**, v. 17, p. 261-272, 2020.

WASKOM, M. L. seaborn: statistical data visualization. **Journal of Open Source Software**, v. 6, n. 60, p. 3021, 2021.